

Aluno: Henrique De Nadai Salvador

1) Descrição do Dataset e Justificativa

Para a realização deste projeto, foi selecionado o dataset público "Microsoft Cats vs Dogs" (<https://www.kaggle.com/datasets/shaunthesheep/microsoft-catsvsdogs-dataset?resource=download>), disponível na plataforma Kaggle. O dataset original contém mais de 20.000 imagens de gatos e 20.000 de cachorros.

Justificativa: Optou-se por utilizar um subconjunto de 4.000 imagens (sendo 2.000 da classe "cat" e 2.000 da classe "dog"). Essa redução foi estrategicamente aplicada para evitar gargalos de processamento local (travamentos na máquina durante o upload e treinamento), garantindo uma execução fluida. Apesar da redução, o volume de 4.000 imagens é estatisticamente excelente e mais do que suficiente para que o modelo aprenda as features necessárias para diferenciar os animais, especialmente considerando o uso de Transfer Learning pela plataforma Teachable Machine.

2) Processo de Treinamento no Teachable Machine

O treinamento do modelo foi realizado no Google Teachable Machine. O processo consistiu nas seguintes etapas:

- 1) Criação de duas classes (labels) distintas: cat e dog.
- 2) Upload do dataset balanceado de 4.000 imagens divididas em suas respectivas categorias.
- 3) Treinamento na própria interface gráfica da ferramenta.
- 4) Exportação do modelo treinado no formato TensorFlow.js, resultando nos arquivos estruturais do modelo (model.json, metadata.json e weights.bin).

3) Descrição da Implementação Web

A aplicação web foi desenvolvida com foco em usabilidade e na aplicação prática do modelo exportado. A interface foi construída utilizando HTML5 e CSS3, com a lógica estruturada em JavaScript.

O funcionamento técnico é sustentado pela biblioteca TensorFlow.js (@tensorflow/tfjs), que permite carregar os pesos do modelo e realizar as inferências diretamente no navegador do usuário, sem a necessidade de um servidor backend para processamento da IA.

Funcionalidades Implementadas:

- Teste Individual (Upload): O usuário pode carregar imagens locais do computador para classificação unitária.
- Teste Individual (Webcam): Integração com a API de mídia do navegador (conforme requisito da etapa 3), permitindo captura de imagem em tempo real para inferência.

- **Avaliação em Lote:** Um módulo de testes em massa foi programado para validar imagens separadas para a Etapa 4 (Princípio de Pareto), calculando automaticamente a Matriz de Confusão e as métricas de performance (Acurácia, Precisão, Recall e F1-Score).

4) Resultados da Avaliação do Modelo

Para validar a confiabilidade do modelo, um lote de testes foi submetido ao sistema de avaliação da aplicação web. O teste atual focou na validação da classe positiva (cat).

Métricas Obtidas:

Total de imagens processadas: 52

Acurácia: 98.08%

Precisão: 100.00%

Recall: 98.08%

F1-Score: 99.03%

Matriz de Confusão (Cat = Positivo):

Verdadeiros Positivos (TP - cat→cat): 51

Falsos Negativos (FN - cat→dog): 1

Falsos Positivos (FP - dog→cat): 0

Verdadeiros Negativos (TN - dog→dog): 0

Análise dos Resultados:

O modelo demonstrou uma performance excelente, com um F1-Score de 99.03%. A precisão de 100% indica que, quando o modelo previu que a imagem era um gato, ele estava absolutamente correto (nenhum cachorro foi classificado como gato neste lote). Houve apenas 1 falso negativo, indicando que uma única imagem de gato possuía características que confundiram a rede neural, levando-a a prever a classe oposta.

5) Conclusões

Conclusão:

O pipeline completo de Machine Learning foi executado com sucesso. Desde a curadoria dos dados, passando pelo treinamento via Transfer Learning, até o deployment em uma aplicação web funcional rodando client-side com TensorFlow.js. Os resultados provam que a rede neural conseguiu generalizar muito bem as diferenças morfológicas entre cães e gatos, validando a escolha do tamanho do dataset (4.000 imagens).

